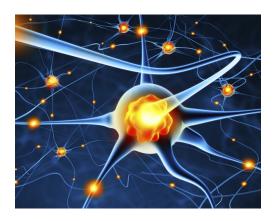






RAPPORT DE STAGE CLASSIFICATION DES CACHALOTS PAR LEURS CLICS



 $Universit\'e \ des \ Antilles \\ Laboratoire \ de \ Math\'ematiques \ Informatique \ et \ Application \ (LAMIA)$

Table des figures

1.1	Figure 1 Schéma de l'organisation interne du LAMIA: ¹ Apprentissages Interactions Données. ² Data analytics and big data gathering with sensors. ³ Mathématiques (analyse variationnelle, analyse numérique, EDP, analyse statistique, mathématiques discrètes).	
	⁴ Membres permanents : Suzy Gaucher-Casalis (MCF), Enguerran Grandchamp (MCF–HDR), Jean-Luc Henry (MCF), Jimmy Nagau (MCF), Vincent Pagé(MCF), Helene Paugam Moisy (PR), Sébastien Régis (MCF), Céline Rémi (MCF)	
$2.1 \\ 2.2$	Fonctionnement d'un neurone seul	;
4.1	Nous avons ici un exemple de code exécuté avec colab	1
5 1	Architecture scale free	1

Table des matières

1	Inti	oduction	3
	1.1	Présentation de la structure d'accueil	3
		1.1.1 L'université des Antilles	3
		1.1.2 Le LAMIA	4
	1.2	Objectifs du groupe Spiketrain	5
	1.3		5
	1.4		5
2	Dér	oulement	6
	2.1	Analyse des données	7
3	ana	lyse des données	9
		3.0.1 Traitement du signal	9
		3.0.2 Data augmentation	9
		3.0.3 difficultés rencontrées	9
	3.1	le travail a distance	9
4	\mathbf{letr}	availadistance 1	0
		4.0.1 Outils utilisés	0
		4.0.2 Présentation de GitHub	0
		4.0.3 Présentation de Google Colab	0
		4.0.4 Présentation de LaTex	1
5	Cor	clusion 1	2
	5.1	Conclusion de l'étude	2
	5.2	Piste d'amélioration	2
		5.2.1 Changer architecture du réseau (Barabasi)	2
		5.2.2 Réinterprétation de l'expérience	2
	5.3	Les apports du stage	2
		5.3.1 les apports au monde	
		5.3.2 les apports personels	2

Introduction

1.1 Présentation de la structure d'accueil

Durant la période de mon stage, j'ai été accueilli au Laboratoire de Mathématiques Informatique et Application (LAMIA) de l'Université des Antilles (UA).

Pour présenter cette structure, il me faut tout d'abord présenter l'université à laquelle il est rattaché.

1.1.1 L'université des Antilles

Bien que ce soit l'université dans laquelle j'ai fait toutes mes études, voici quelques chiffres que je ne connaissais pas et qui donnent la mesure de sa taille :

L'Université des Antilles s'organise autour deux pôles universitaires régionaux autonomes : le « Pôle Guadeloupe » et le « Pôle Martinique ».

Sur ces pôles, l'Université assure des missions d'enseignement et de recherche, assistées par des administratifs et des techniciens.

Administration et personnel technique

l'UA emploie 414 Administratifs et Techniciens (environ 200 personnes pour l'administation centrale et 100 répartis sur chaque pôle)

Enseignements

L'UA délivre des diplomes de la licence au doctorat dans de nombreux domaines. Au total, cela représente :

- 484 enseignants-chercheurs (environ 240 pour chaque pôle)
- 12 000 étudiants (environ 7000 pour la Guadeloupe, 5000 pour la Martinique)

Pour l'informatique, cela représente : - autour de 20 enseignants-chercheurs - autour de 120 étudiants

Recherche

La recherche est structurée en laboratoires auxquels sont rattachés les enseignants chercheurs qui peuvent former de futurs chercheurs : les doctorants.

L'université compte ainsi au total :

- 17 laboratoires
- 320 doctorants

Pour ma part, comme signalé précédemment, j'ai effectué mon stage dans le laboratoire LAMIA que je vais maintenant présenter.

1.1.2 Le LAMIA

Le Laboratoire de Mathématiques Informatique et Application (LAMIA), comme son nom l'indique, se concentre sur les recherches en informatiques et mathématiques.

Il compte une soixantaine de membres (Professeurs des Universités, Maitres de Conférences, ATER, Doctorants) répartis sur deux pôles (Guadeloupe et Martinique) au sein de trois équipes internes :

- Equipe **Mathématiques** (analyse variationnelle, analyse numérique, EDP, analyse statistique, mathématiques discrètes);
- Equipe Informatique **DANAIS**: Data analytics and big data gathering with sensors;
- Equipe Informatique **AID**: Apprentissages Interactions Donnees;

De plus, le LAMIA accueille en son sein un groupe de chercheurs associés travaillant en Epidémiologie clinique et médecine.

L'équipe avec laquelle il m'a été donné de travailler principalement est celle d'**Apprentissages** Interactions Données qui développe des méthodes de traitements et d'analyse de données hétérogènes : images (classique, multi-spectrale), séquences vidéos, séries temporelles et spatio-temporelles, dont la responsable est Mme. Hélène Paugam-Moisy.

Indépendamment de ces équipes, les travaux de recherche du laboratoire se répartissent en **projets** qui peuvent réunir des membres de plusieurs équipes en **groupes de travail**. Mon stage était en fait plus attaché à un projet et un groupe de travail qu'à une équipe.

Ce projet est nommé de façon informelle projet "Spikes" et concerne l'utilisation de réseaux de neurones impulsionnels pour l'apprentissage automatique (ces notions seront définies plus loin). Le groupe de travail associé réunit à l'heure actuelle :

- 1 Professeur des Universités
- 2 MCF avec HDR
- 3 MCF
- 1 ingénieur d'études.

C'est avec ces personnes que j'ai travaillé tout au long du stage et mes tuteurs de stage était M. Vincent PAGÉ et M. Manuel CLERGUE.

Ci dessous, un schéma présentant la structure du laboratoire mon rattachement à cette structure. (L'équipe de travail **Spikestrain** étant informelle, elle ne figure pas sur ce schéma.)

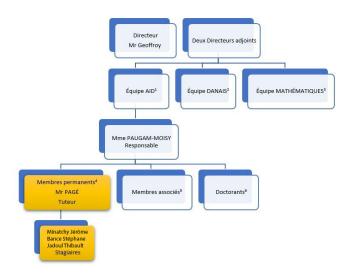


FIGURE 1.1 – Figure 1 Schéma de l'organisation interne du LAMIA : ¹Apprentissages Interactions Données. ²Data analytics and big data gathering with sensors. ³Mathématiques (analyse variationnelle, analyse numérique, EDP, analyse statistique, mathématiques discrètes). ⁴Membres permanents : Suzy Gaucher-Casalis (MCF), Enguerran Grandchamp (MCF–HDR), Jean-Luc Henry (MCF), Jimmy Nagau (MCF), Vincent Pagé(MCF), Helene Paugam Moisy (PR), Sébastien Régis (MCF), Céline Rémi (MCF).

La prochaine section sera consacrée à la présentation de la thématique de recherche du groupe "Spikes" et de mon stage.

1.2 Objectifs du groupe Spiketrain

Le groupe **Spikestrain** s'intéresse aux techniques d'**Intelligence Artificielle**, plus spécifiquement à l'**apprentissage automatique** dont l'objectif est de créer des programmes capable d'apprendre à partir de bases d'exemples.

Actuellement, parmi les techniques permettant l'apprentissage automatique, une se démarque et est très populaire : les **réseaux** de **neurones artificiels**, notamment dans leur version *profonde* qui sont très utilisé par exemple par **Facebook**™ pour sa **reconnaissance faciale** ou encore par **Google**™ pour ses **robots** qui apprennent par **répétitions** à jouer (échecs, Go).

1.3 Réseaux de neurones classiques

Ces réseaux de neurones artificiels sont nés dans les années 1960 et les techniques d'apprentissage arrivent à maturité seulement maintenant, avec des résultats très impressionnants.

Bien que basés de façon lointaine sur des neurones biologiques, ils sont en fait très peu plausibles biologiquement (les neurones échangent des chiffres entre eux, les informations se rétropropagent...)

1.4 Problématique : Classifier les Cachalots

Le challenge "Dyni Odontocete Click Classification, 10 species [DOCC10] by Universite de Toulon" (https://challengedata.ens.fr/challenges/32) consistait simplement à réaliser un classifieur qui classe les cachalots en une dizaine d'especes à partir de leurs "Clics" pour celà nous avions a disposition une base d'apprentissage labelisée ainsi qu'une base de test non labelisée sur laquelle nous pouvions évaluer les performances réelles de nos classifieurs. Pour cela nous labelision les exemples de la base de test puis envoyions nos prédictions sur le site du challenge qui nous renvoyais nos performances ainsi qu'un classement des performances de tous les participants.

Les deux bases sont consititués d'enregistrements audios des clics des différentes especes de cachalots que je présenterais plus en détail dans la partie analyse des données.

Déroulement

Quand je suis arrivé dans l'équipe plusieurs solutions basés sur les réseaux de neurones avaient déjà été explorés par mes tuteurs. La première partie sera donc consacrée à la découverte théorique des réseaux de neurones artificiels et a la convolution.

Neurone artificiel

Tout d'abord avant de parler de réseaux de neurone à spike il serait de bon ton d'expliquer le principe du réseau de neurone classique, explication qui commencera par expliquer le le principe du neurone unique.

Un neurone artificiel est pourvu d'un certain nombre d'**entrées**. Dans le cas des neurones classiques, ces entrées sont des nombres réels. Le neurone calculera, en fonction de ces entrées, une unique valeur en **sortie**. Détaillons la façon dont ces calculs sont effectués :

Chacune de ces entrées circule sur une connection, laquelle est caractérisée par un **poids** qui définit l'importance de l'entrée pour le neurone.

Le neurone calcule dans un premier temps la somme de ses entrées, pondérée par leurs poids respectifs, à laquel vient s'ajouter un **biais** spécifique à chaque neurone (cf. equation 2.1).

$$y = \sum_{i=1}^{n} w_i \times x_i + b \tag{2.1}$$

Le résultat de cette somme passe alors dans une fonction d'activation qui permet d'introduire une non-linéarité dans les calculs. La sortie s du neurone est donc calculée conformément à l'équation 2.2

$$s = f(\sum_{s=0}^{n_x} x_n w_n + b) (2.2)$$

Un schéma reprenant ces explications est présenté dans la figure ??:

Notre apprentissage ce fera en modifiant les poids de ses différentes connexion (et le biais) de façon à obtenir une sortie proche de celle voulu.

Réseaux de neurones

Les neurones présentés précédemment prennent tout leur intérêt lorsqu'ils sont utilisés en groupes, dans des **réseaux de neurones**.

Le premier de ces réseaux, encore utilisé de nos jours, est appelé **perceptron**. Le principe du perceptron n'est pas nouveau et date des années 1960.

Dans ces réseaux, les neurones sont organisés en **couches**. La première couche correspond à celle qui permettra d'introduire des informations dans le réseau (comme la rétine par exemple). Elle est nommé **couche d'entrée** La dernière couche permettra de lire les décisions du réseau. Elle est appelée **couche de sortie**. Dans les applications classiques, à chaque neurone de la couche de sortie correspond une




Figure 2.1 – Fonctionnement d'un neurone seul

décision possible et le neurone qui est le plus activé sur la couche de sortie l'emporte. Entre ces couches, on trouve souvent un nombre variable de couches intermédiaires appelées **couches cachées**.

Entre deux couches, on établit le plus souvent un schéma de connexion que nous pouvons qualifier de *full connected*, c-a-d que chaque neurone d'une couche est connecté avec chaque neurone de la couche suivante. Nous allons encore une fois, pour le bien de ce rapport, ne pas épiloguer sur les autres types de connexions existantes.

Nous allons, pour cette partie encore, utiliser une figure (2.2) pour illustrer nos propos:

2.0.1 la convolution

Quand j'ai commencé mon stage mes tuteurs avaient déjà commencé le challenge depuis un moment déjà c'est pourquoi j'ai du dans un premier temps me mettre à jours sur le challenge et ce qu'ils avaient fais.

De plus ceux ci rencontraient un problème récurant qui était une grande disparité dans leurs résultats sur la base labelisée et leurs résultats sur la base non labelisée. C'est entre autre pour cette raison que j'ai été chargé de m'occuper de l'analyse des données

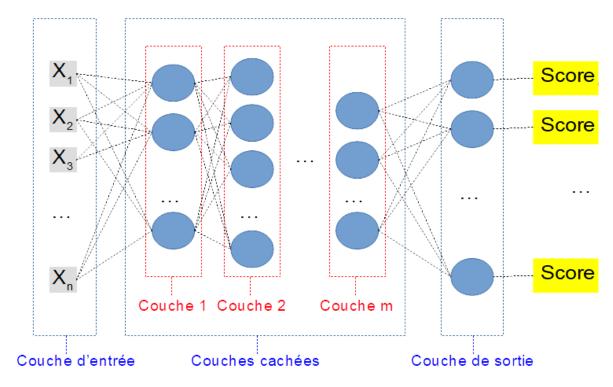


FIGURE 2.2 – réseau de neurones classique en couches

Analyse des données

- 3.0.1 La base d'apprentissage
- 3.0.2 La base de test
- 3.0.3 Traitement du signal
- 3.0.4 Data augmentation
- 3.0.5 difficultés rencontrées

Le travail a distance

4.1 Le travail a distance

Comme vous le savez certainement durant cette année 2020 nous avons été touchés par la crise du coronavirus qui nous a conduit a être confinés nous forçant a travailler uniquement a distance.

Ces circonstances très particulières ont grandement affecté notre travail particulérement au début ou nous avons du régler de nombreux problèmes techniques et organisationels. Cependant en nous forçant a nous adapter a ces nouvelles conditions, cette crise nous a permis de grandement augmenter nos competances en "télétravail".

Ainsi malgrés des débuts léthargiques nous avons mis en place une "routine de travail" qui était la suivante : -Des visio-conférences quotidiennes nous permettant d'organiser et de synchroniser notre travail -Un groupe whatsap dédié a mon stage afin de communiquer le plus efficacement possible -Un Github privé dédié afin de partager l'ensemble du projet -Un partage régulier de google collab via google drive

4.1.1 Outils utilisés

4.1.2 Présentation de GitHub



Nous pouvons définir GitHub comme une plateforme de développement de projet in formatique en groupe. Elle s'implifie grandement le développement de projets. Elle permet de versioner ses programme et d'y apporter des modification en temps réel à plusieurs.

Pourquoi Github

Car celà permet une certaine synergie avec nos autres outils que nou verrons plus tard. Cette plateforme permet une facilité de développement de par sa fonctionnalité de versionnage de notre code à chaque changement ce qui permet une mise à jour dynamique ainsi que une relative facilitée a retourner à un état entérieur de notre programme ce qui permet une faciliter de débogage. Nous pouvons d'ailleur dire que ce rappport est entreposer sur Github et qu'il peut être récupérer facilement. Cette plateforme est aussi très connu dans le monde de la programmation ce qui sera utile pour notre future professionnel.

4.1.3 Présentation de Google Colab

Colab peut-être défini comme étant une plateforme d'éxécution pour notre code il permet du fait que ce soit la puissance de calcul d'ordinateur géré par Google une vitesse d'exécution ainsi qu'une vitesse



de téléchargement de base de données supérieur à celle qui nous est disponible en local.

Pourquoi Colab

En premier lieu pour la faciliter d'exéccution du code car ce n'est pas en local ce qui permet une exécution quasi immédiate du code sans aucune installation. Il est aussi facile de mettre sur github du code produit avec colab car c'est deux plateforme sont liées. Il permet de par l'utilisation du format Jupyter de mélanger code et texte (peu aussi comporter des images) dans notre notebook.

Voilà un exmple d'exécution avec colab :




FIGURE 4.1 – Nous avons ici un exemple de code exécuté avec colab.

4.1.4 Présentation de LaTex



Nous pouvons dire que LaTex est un langage de traitement de texte tel que le markdown qui permet de mettre en forme notre texte de manière scientifique ela veut dire que. LaTex permet une faciliter d'écriture des équations et de toutes les écriture mathématiques. Permet de par ses nombreux package une quasi-infinité de possibilitées.

Conclusion

5.1 Conclusion de l'étude

Nous avons tout d'abord vu avec notre modèle de simulation qu'il fallait tout d'abord limité l'influence de l'aléatoire de notre simulations

5.2 Piste d'amélioration

5.2.1 Changer architecture du réseau (Barabasi)

Nous avons envisagé de changer la **topologie**¹. Pour passer à une topologie dite **scalefree**. Qui est justement celle utilisé dans l'article d'origine. Cette architecture ressemble à ça :

5.2.2 Réinterprétation de l'expérience

Nous pouvons interpréter tout le réseau comme un utilisateur et cet entretient comme le temps qu'il accorde à la rumeur.

Cela permettrait

5.3 Les apports du stage

5.3.1 les apports au monde

Grâce à ce stage les chercheurs du laboratoire auront une idée plus précise de la diffusion d'un echo dans un réservoir et comment y créer un entretient ce qui sera utile pour leurs futures expériences. Cela permettra de mieux appréhender certains problèmes.

5.3.2 les apports personels

Comme dit pendant mon introduction, avant ce stage je n'avais aucune connaissance des réseaux de neurones, ce stage m'a donc permis de m'ouvrir a ce nouveau sujet passionnant, et m'a permis d'obtenir des compétence nécéssaire à mon cursus universitaire. Il m'a permis d'affiné mes méthodes de travail grâce à l'apprentissage de l'utilisation de GitHub et Colab. J'ai amélioré ma rédaction grace à l'approfondissement du LaTeX. Il m'a permis d'affiner mon analyse de par l'analyse de mes résultats.

^{1.} Topologie : Tel que la topologie d'un graffe il s'agit de la façon dont sont connecté nos neurones entre eux.




FIGURE 5.1 – Architecture scale-free